DATA SCIENCE NA GESTÃO EMPRESARIAL: Uma análise das práticas nos negócios.

Filipi Pereira dos Santos - INSTITUTO BRASILEIRO DE GESTÃO DE NEGÓCIOS (IBGEN)

Tatiane Pereira Librelato – GMAP (UNISINOS)

Marilia Botelho Coelho – GMAP (UNISINOS)

Geraldo Luiz F. da Silva – Universidade Federal de Rondônia (UNIR)

Gisele de Macedo Steffen– GMAP (UNISINOS)

A tomada de decisão por parte dos gestores de negócios é um processo complexo que envolve alto volume de dados. Neste sentido, as técnicas de Design Science & Analytics (DS) podem ser utilizadas para tornar o processo mais veloz e assertivo. Este estudo tem por objetivo identificar como as aplicações de DS podem contribuir para a gestão empresarial. Para isso, foi elaborado um protocolo para revisão sistemática da literatura combinado, utilizando a estratégia de condução Literature Grounded Theory – LGT (Ermel, et al. (2022). Por meio de uma revisão sistemática da literatura é proposto um framework conceitual. Por meio destes resultados, os gestores de negócios podem identificar as principais técnicas de DS recomendadas para cada tipo de problema, associados a contextos distintos dos negócios, em especial, na previsão e modelagem de variáveis que influenciam a gestão empresarial. A partir de tal identificação, é possível comparar com a realidade da empresa, o que permite o encaminhamento de ações de melhoria.

Palavras-chave: Design Science & Analytics (DS), Gestão Empresarial, Literature Grounded Theory.

1. Introdução

Os sistemas empresariais possuem alto volume de dados, o que contribui para torná-los complexos. Identificar, nos dados disponíveis, padrões que possam contribuir no processo decisório das empresas é um desafio para os gestores. A complexidade presente na gestão empresarial, somada a fatores internos e externos, tornam relevante o uso de técnicas para a busca de padrões e análise de informação, que possam contribuir para a tomada de decisões mais assertivas, associadas aos negócios (WASSERBACHER; SPINDLER, 2022).

Nesta perspectiva, a ciência de dados (*Data science & Analytics* – DS) contribui com princípios fundamentais que orientam a extração de conhecimento, a partir dos dados (PROVOST; FAWCETT, 2013). DS é um campo interdisciplinar que utiliza algoritmos e métodos científicos para obter insights a partir dos dados para inferir padrões (VAN DER AALST, 2016). Por meio do uso de DS, tornou-se possível a construção de sistemas analíticos mais adequados para lidar com os altos volume e variedade de dados, contribuindo para a tomada de decisão dos gestores mais veloz e assertiva e para o desempenho do negócio (VERMEULEN, 2018). Compreender a tecnologia aplicada em dados como parte importante na gestão empresarial tem se mostrado cada vez mais efetivo para o crescimento de valor de mercado de uma empresa, tornando-se um fator estratégico. Entretanto, as organizações apresentam dificuldades na identificação de como, quando e quais métodos de análise de dados utilizar, de acordo com o contexto organizacional, bem como quais resultados podem ser esperados a partir do uso destas aplicações (CAFFO *et al.*, 2018).

Sendo assim, esta pesquisa se propõe a responder *Como as aplicações de Data Science & Analytics (DS) podem contribuir para a gestão empresarial?* O objetivo geral proposto é identificar as aplicações de DS utilizadas na gestão de empresarial por meio de uma amostra de revisão da literatura. Para alcançar o objetivo geral, foram estabelecidos três objetivos específicos: i) identificar as principais técnicas de DS utilizados na gestão empresarial; ii) identificar as motivações para utilização dessas técnicas na gestão de negócios e iii) identificar os resultados esperados com a aplicação das técnicas de DS em processos de gestão.

Esta pesquisa está estruturada em 5 seções. Além da introdução, que aborda a contextualização deste estudo, a seção 2 aborda os principais conceitos que suportam a pesquisa. A seção 3 apresenta a metodologia para condução deste estudo. A seção 4 apresenta os resultados encontrados, enquanto a seção 5 apresenta as considerações finais, limitações e indicações de estudos futuros.

2. Referencial teórico

Esta seção apresenta os principais conceitos que sustentam este estudo. São apresentadas as principais características do *Data Science &Analytics* (DS) e as principais técnicas de DS aplicadas no contexto dos negócios.

2.1 Data Science & Analytics (DS)

DS é um campo interdisciplinar que utiliza algoritmos e métodos científicos para obter insights a partir dos dados (VAN DER AALST, 2016), permitindo inferências. DS está associada ao paradigma do progresso científico (HEY, TANSLEY E TOLLE, 2009) e tem sido cada vez mais aplicado no meio empresarial, em campos de estudos variados, tais como economia (VICARIO; COLEMAN, 2019), finanças (GIUDICI, 2018), operações (OHLSON, 2022), entre outros. Provost e Fawcett (2013) propõem uma divisão em grupos de técnicas, denominadas como tarefas, nas quais a DS pode contribuir com soluções para diversos problemas organizacionais. O Quadro 1 enumera tais Tarefas, nomeadas conforme seus objetivos. Contém os nomes em português e inglês, como apresentados pelos autores.

Quadro 1 – Tarefas de DS

ID	Tipo (Pt-Br)	Técnica (Eng.)	Objetivo
T01	Classificação	*Classification*	Estimar a probabilidade de uma classe.
T02	Regressão	*Regression*	Estimar uma variável contínua.
T03	Agrupamento	*Clustering*	Agrupar indivíduos.
T04	Similaridade	*Similarity*	Encontrar indivíduos com atributos semelhantes.
T05	Regras de associação	*Association Rules*	Encontrar coocorrências baseado nas transações.
T06	Criação de Perfis	*Profiling*	Caracterizar o comportamento típico de um indivíduo.
T07	Redução Dimensional	*Data reduction*	Reduzir quantidade de dados por uma amostra estatisticamente representativa.
T08	Redes	*Network*	Analisar conexões e forças entre itens.
T09	Modelagem Causal	*Causal modeling*	Entender eventos ou ações que influenciaram outros.
T10	Séries temporais	*Time Series*	Lidar com dados históricos e todas as suas subtarefas.

Fonte: Provost e Fawcett (2013) - Adaptado

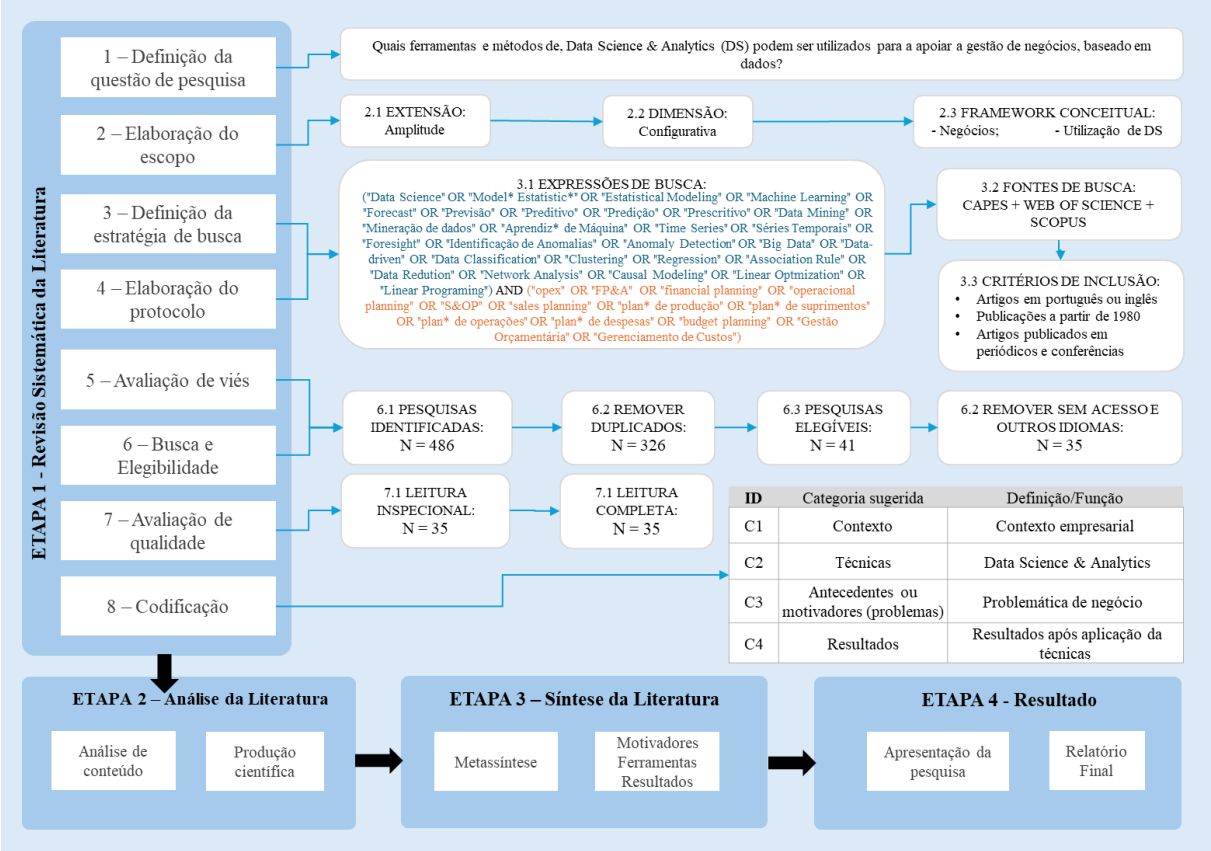
As técnicas descritas no Quadro 1 podem ser aplicadas em problemas organizacionais distintos. Por exemplo, a identificação de maus e bons pagadores ou propensão de deixar de ser cliente, seriam aplicações da tarefa de Classificação (T01); estimar o volume de venda ou estoque seria uma tarefa de Regressão (T02) ou Séries temporais (T10); As tarefas de Agrupamento (T03), Similaridade (T04) e Criação de Perfis (T06) podem ser utilizadas para identificar transações financeiras com comportamento aproximado em relação às variáveis analisadas; a tarefa de regras de associação (T05) encontrar padrões de consumo de produtos e utilização de insumos;

Redução Dimensional (T07), identificar os atributos que mais impactam a variabilidade dos dados; Redes (T08), analisar o relacionamento entre o perfil de clientes; Modelagem Causal (T09), entender quais variáveis mais impactam na perda de clientes.

3. Procedimentos metodológicos

Este capítulo apresenta os procedimentos utilizados para condução do estudo, incluindo o método de trabalho, método de pesquisa, e técnicas para coleta e análise dos dados. O método é o conjunto das atividades sistemáticas e racionais, reconhecidos pela comunidade acadêmica e utilizados pelos pesquisadores para a construção do conhecimento científico (DRESCH; LACERDA; ANTUNES JÚNIOR, 2015). Assim, para responder ao problema de pesquisa, foi elaborado um protocolo para revisão sistemática da literatura combinado com o método de trabalho (Figura 1), aplicando a estratégia de condução *Literature Grounded Theory* – LGT, proposto por Ermel, *et al.* (2022).

Figura 1: Etapas da Revisão Sistemática de Literatura



Fonte: Elaborado pelos autores.

Conforme apresenta a Figura 1, o método de trabalho está organizado em 4 etapas e segue as recomendações de Dresch, Lacerda e Antunes Júnior (2015). Foram definidas as bases de dados que fazem parte da pesquisa, expressões de busca e suas combinações, bem como critérios de inclusão. O horizonte de pesquisa foi definido a partir de 1980, para uma análise contextual mais abrangente. A coexistência do contexto empresarial e da utilização de técnicas de DS foi o principal critério utilizado para a seleção dos estudos. Assim, aplicando-se as estratégias de busca, critérios de inclusão e critérios de elegibilidade, 35 estudos foram selecionados como *corpus* de análise e numerados para facilitar a discussão (apresentados no Apêndice A). Estes configuram as unidades de contexto. Para coletar os dados, foi estabelecido um esquema de codificação misto aplicado às unidades de contexto, apresentado no Quadro 2.

Quadro 2 – Esquema de codificação

ID	**Categorização** (do código)		**Categoria**	**Definição**
C1	Fechado		Contexto	Contexto empresarial
SC1		Aberto	Contexto - Custos	Custos
SC2		Aberto	Contexto - Financeiro	Financeiro
SC3		Aberto	Contexto - S&OP - Operações	S&OP - Operações
SC4		Aberto	Contexto - S&OP - Vendas	S&OP - Vendas
SC5		Aberto	Contexto - Supply Chain	Supply Chain
C2	Fechado		Técnicas /Tarefas de DS	*Data Science & Analytics*
C3	Fechado		Antecedentes	Motivadores / Problemática de negócio
C4	Fechado		Resultados	Resultados com a aplicação das técnicas

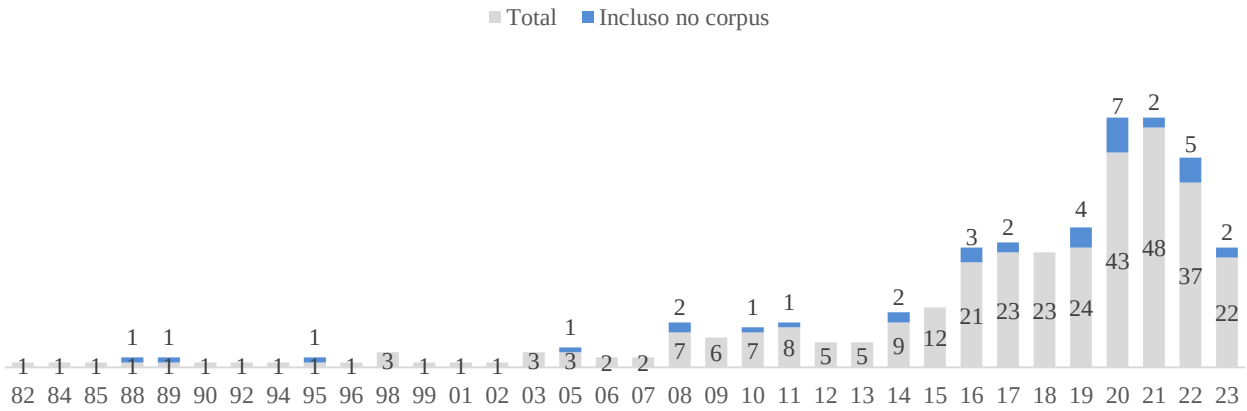
Fonte: Elaborado pelos autores.

Conforme apresenta o Quadro 2, a categoria C1 trata de mapear o contexto empresarial em que o estudo foi realizado. Na categoria C2 aborda-se as Técnicas de DS utilizadas em tais estudos para solução de problemas abordados (C3) no contexto empresarial específico (C1). A categoria C2 foi ainda desdobrada em 10 Tarefas, de acordo com a classificação apresentada no Quadro 1. As categorias SC representam o desdobramento do C1 e formam um conjunto de códigos abertos, ou seja, criados a posteriori. Para a etapa de análise de conteúdo, as unidades registro codificadas foram analisadas por meio das regras de recorte, categorização e enumeração, seguindo as recomendações de Dresch, Lacerda e Antunes Júnior (2015) e Bardin (2011), dividida entre as etapas de pré-análise, exploração do material, tratamento e interpretação dos resultados.

4. Discussão dos Resultados

Os dados cientométricos são apresentados no Gráfico 1. A análise cientométrica verificou dados de produção científica anual visando identificar o desenvolvimento do tema.

Gráfico 1 – Dados cientométricos por ano de publicação



Fonte: Elaborado pelos autores.

Conforme evidencia o Gráfico 1, é possível observar maior concentração da quantidade de artigos triados envolvendo os termos de busca após o ano de 2008 (92%), sendo que 71% dos estudos foram realizados após de 2016. A concentração de estudos recentes sugere o interesse crescente da comunidade acadêmica e empresarial sobre o tema. A análise da literatura identificou que os estudos foram realizados sob óticas diferentes, o que inclui empresas de segmentos e objetivos diferentes. Considerando-se tais elementos, foram definidos cinco contextos. A tabela 1 apresenta os estudos categorizados por contexto, segmentando as pesquisas conforme os seus objetivos.

Tabela 1 - Contextos

ID	Contexto	Qt.	%	Estudos
SC1	Custos	10	29%	5, 9, 14, 16, 18, 20, 22, 24, 26, 31
SC2	Financeiro	9	26%	8, 11, 13, 15, 21, 25, 27, 34, 35
SC3	S&OP - Operações	4	11%	4, 12, 19, 32
SC4	S&OP - Vendas	9	26%	1, 2, 3, 7, 10, 17, 28, 29, 33
SC5	Supply Chain	3	9%	6, 23, 30
	TOTAL	35	100%	-

Fonte: Elaborado pelos autores.

O contexto de Custos (SC1) aborda estudos relativos à predição de custos de projeto, fabricação e operação da cadeia de suprimento e à otimização de recursos limitados perante cenários

diversos. O contexto Financeiro (SC2) envolve estudos focados em prever resultados em termos de lucratividade, tais como fluxo de caixa, liquidez e razões financeiras. O contexto S&OP (Sales & Operations) foi dividido em Vendas (SC4), com objetivos ligados a definição de preços e previsão de vendas, e Operações (SC3), ligados a plano de produção, previsão de demanda, estoque e gargalos. O contexto Supply Chain (SC5) ou Cadeia de Suprimento, envolve os temas ligados a maximização de eficiência de recursos logísticos diante de múltiplos cenários.

Por meio da análise da literatura foi possível identificar que cada estudo apresenta diferentes problemas (antecedentes) que motivaram a aplicação das tarefas de DS envolvidos na tomada de decisão organizacional. Estes motivadores foram agrupados, conforme apresenta a Tabela 2, e representam os principais problemas relatados pelas organizações.

Tabela 2 – Motivadores por grupo

ID	Agrupamento	Motivador	Qt.	Estudos
M01	Volume de dados	O gerenciamento eficaz do volume de dados é essencial para evitar gargalos no processo de orçamentação (LI; PENG; XING, 2019).	4	3, 19, 22, 30
M02	Complexidade de composição	A complexidade na composição orçamentária demanda abordagens inovadoras para garantir a transparência, alinhamento estratégico e facilidade na tomada de decisões (SIMONS, 2014).	11	1, 4, 8, 11, 13, 17, 19, 22, 23, 27, 30
M03	Visibilidade dos dados	A padronização de dados é uma etapa fundamental na construção de orçamentos eficazes, garantindo uniformidade e confiabilidade nas informações utilizadas (LAPCHAK, PAUL; ZHANG, 2018).	3	15, 22, 29
M04	Previsibilidade dos indicadores	Previsões precisas e planos para alocação de recursos eficazes e eficientes são entregas essenciais da gestão. Em ambientes de mercado voláteis ou de rápida evolução, previsões e planejamentos rápidos e confiáveis são ainda mais importantes (BECKER *et al.*, 2016).	27	1, 2, 3, 5, 6, 7, 9, 10, 11, 12, 13, 14, 15, 16, 17, 18, 19, 20, 21, 24, 25, 28, 29, 31, 32, 33, 34
M05	Acurácia das estimativas	A acurácia das estimativas do uso de recursos é vital para a credibilidade dos processos, influenciando diretamente a confiança dos stakeholders e a eficácia das decisões gerenciais (HILTON & PLATT, 2013).	11	2, 3, 5, 10, 12, 13, 17, 19, 21, 25, 26
M06	Monitoramento	Monitorar os resultados é uma necessidade constante para os negócios que desejam se manter competitivos e tomar decisões mais ágeis. Tais decisões estão relacionadas ao mercado, concorrência e ao processo de melhoria contínua (GANGWAR *et al.*, 2023).	8	4, 5, 9, 16, 22, 23, 26, 34
M07	Risco e incertezas	A gestão efetiva de riscos e incertezas no processo é essencial para mitigar impactos negativos e promover a resiliência organizacional (BRIGHAM; EHRHARDT, 2016).	6	19, 21, 24, 31, 32, 35

ID	Agrupamento	Motivador	Qt.	Estudos
M08	Otimização de variável objetivo	A otimização de resultados no âmbito da otimização matemática requer a aplicação de métodos analíticos e algoritmos avançados para encontrar soluções eficientes que maximizem a eficácia dos recursos disponíveis (BAZARAA; SHETTY, 2013).	12	1, 4, 8, 19, 21, 23, 24, 26, 27, 31, 32, 34
M09	Decisão não baseada em dados	A tomada de decisões baseada em dados no contexto dos negócios, exige a capacidade de transformar dados brutos em insights acionáveis, promovendo uma gestão mais informada e eficiente (DAVENPORT; HARRIS, 2007).	15	1, 2, 4, 8, 10, 16, 17, 20, 22, 23, 25, 26, 27, 32, 35
		TOTAL	35	

Fonte: Elaborado pelos autores com base na literatura

Conforme apresentado na Tabela 2, a "Previsibilidade" (77%) e "Decisões baseadas em dados" (43%) são os principais motivadores encontrados. É importante destacar que um estudo pode fazer parte do agrupamento de motivadores diferentes. Por exemplo, o estudo 1 faz parte de 4 grupos de motivadores. No contexto das tarefas utilizadas, a escolha do algoritmo adequado depende do problema específico que se está buscando resolver e não existe um único algoritmo que funcione perfeitamente para todos os cenários (DOMINGOS, 2015). Portanto, comparações e experimentações tendem a apontar o melhor modelo para cada aplicação e a melhor solução pode ser uma combinação entre modelos.

Tabela 3 – Frequência de artigos por Tarefa

ID	Técnica	Qt.	Estudos
T01	*Classification*	1	15
T02	*Regression*	19	1, 3, 5, 6, 9, 10, 12, 13, 16, 17, 20, 21, 24, 26, 28, 29, 33, 34, 35
T03	*Clustering*	2	19, 32
T04	*Similarity*	-	-
T05	*Association Rules*	-	-
T06	*Profiling*	-	-
T07	*Data reduction*	-	-
T08	*Network*	-	-
T09	*Causal modeling*	3	3, 14, 22
T10	*Time Series*	15	1, 2, 3, 6, 7, 10, 12, 18, 19, 21, 25, 29, 31, 34, 35
T11	*Optimization*	7	4, 8, 11, 23, 27, 30, 31
T12	*Multicriterial Decision*	4	4, 11, 27, 30
T13	*NLP*	-	-
T14	*Neural Networks*	3	2, 17, 21
T15	*Reinforcement learning*	-	-
	TOTAL	35	

Fonte: Elaborado pelos autores com base na literatura

Na tabela 3, foram identificadas T02 *Regression* (n=19) e T10 *Time Series* (n=15) como as tarefas mais frequentes (71%). A maior presença dessas tarefas se justifica pelos motivadores que envolvem a previsão de valores contínuos, tais como custos e receitas; e pela otimização dos recursos disponíveis, dadas suas restrições. Os estudos não utilizam as técnicas no momento da formação de um orçamento propriamente dito, mas aplicam as técnicas em seus principais componentes, tais como estimar a receita e custos.

Ao aplicar as tarefas de DS, resultados são esperados pelos gestores. A tabela 4 apresenta o agrupamento dos principais resultados esperados com a aplicação das tarefas de DS.

Tabela 4 – Resultados esperados com DS

ID	Resultado	Qt.	Estudos
R01	Melhor visibilidade das informações	6	8, 9, 15, 22, 29, 35
R02	Suporte para tomada de decisão	34	2, 3, 4, 5, 6, 7, 8, 9, 10, 11, 12, 13, 14, 15, 16, 17, 18, 19, 20, 21, 22, 23, 24, 25, 26, 27, 28, 29, 30, 31, 32, 33, 34, 35
R03	Melhoria na composição de orçamentária	12	4, 9, 16, 21, 23, 24, 25, 26, 27, 31, 32, 34
R04	Mais agilidade no diagnostico	5	5, 6, 17, 29, 34
R05	Melhor acuracidade	16	1, 2, 4, 6, 7, 10, 12, 13, 17, 18, 19, 21, 25, 26, 29, 32
R06	Facilita a projeção de resultados	6	5, 21, 22, 24, 31, 34
R07	Descoberta de padrões ocultos	7	19, 22, 23, 24, 25, 32, 35
	TOTAL	35	

Fonte: Elaborado pelos autores com base na literatura

Conforme quantificado na Tabela 4, os resultados mais desejados pelos gestores, independente das Tarefas ou Contexto, são o R02, que representa o suporte para tomada de decisão, presente em 34 dos 35 estudos (97%). É seguido por R05 e R03, que representam, respectivamente, melhor acuracidade (16 estudos) e melhoria na composição orçamentária (12 estudos). As principais aplicações foram identificadas em situações de negócio que empregaram ferramentas de organização e visualização de dados. Maior clareza para a tomada de decisão foi o principal benefício relatado na literatura. Estes resultados indicam a importância do uso dos dados e do cuidado com sua qualidade, sugerindo que a aplicação analítica é relevante para o ganho de competitividade e sucesso do negócio.

Considerando as tarefas de DS utilizadas (Tabela 3) nos contextos mapeados (Tabela 1) foi possível identificar as principais razões para o uso de DS (Tabela 2) no contexto dos negócios, bem como identificar os principais resultados obtidos e/ou esperados (Tabela 4) por meio de tais aplicações. Este conjunto de informações mapeadas e categorizadas foram recombinadas, dando origem ao *Framework* proposto no Quadro 3. Devido a quantidade de dados, as

categorias são representadas pela codificação apresentada anteriormente e as linhas sem estudos correspondentes, como por exemplo, tarefa T4 (Tabela 3), foram suprimidas.

Quadro 3 – *Framework* proposto

		ID - Motivador								
		M01	M02	M03	M04	M05	M06	M07	M08	M09
Contexto	SC1	22	22	22	5, 9, 14, 16, 18, 20, 24, 31	5, 26	5, 9, 16, 22, 26	24, 31	24, 26, 31	16, 20, 22, 26
	SC2	-	8, 11, 13, 27	15	11, 13, 15, 21, 25, 34	13, 21, 25	34	21, 35	8, 21, 27, 34	8, 25, 27, 35
	SC3	19	4, 19	-	12, 19, 32	12, 19	4	19, 32	4, 19, 32	4, 32
	SC4	3	1, 17	29	1, 2, 3, 7, 10, 17, 28, 29, 33	2, 3, 10, 17	-	-	1	1, 2, 10, 17
	SC5	30	23, 30	-	6	-	23	-	23	23
Tarefas	T01	-	-	15	15	-	-	-	-	-
	T02	3	1, 13, 17	29	1, 3, 5, 6, 9, 10, 12, 13, 16, 17, 20, 21, 24, 28, 29, 33, 34	3, 5, 10, 12, 13, 17, 21, 26	5, 9, 16, 26, 34	21, 24, 35	1, 21, 24, 26, 34	1, 10, 16, 17, 20, 26, 35
	T03	19	19	-	19, 32	19	-	19, 32	19, 32	32
	T09	3, 22	22	22	3, 14	3	22	-	-	22
	T10	3, 19	1, 19	29	1, 2, 3, 6, 7, 10, 12, 18, 19, 21, 25, 29, 31, 34	2, 3, 10, 12, 19, 21, 25	34	19, 21, 31, 35	1, 19, 21, 31, 34	1, 2, 10, 25, 35
	T11	30	4, 8, 11, 23, 27, 30	-	11, 31	-	4, 23	31	4, 8, 23, 27, 31	4, 8, 23, 27
	T12	30	4, 11, 27, 30	-	11	-	4	-	4, 27	4, 27
	T14	-	17	-	2, 17, 21	2, 17, 21	-	21	21	2, 17
Resultados	R01	22	8, 22	15, 22, 29	9, 15, 29	-	9, 22	35	8	8, 22, 35
	R02	3, 19, 22, 30	4, 8, 11, 13, 17, 19, 22, 23, 27, 30	15, 22, 29	2, 3, 5, 6, 7, 9, 10, 11, 12, 13, 14, 15, 16, 17, 18, 19, 20, 21, 24, 25, 28, 29, 31, 32, 33, 34	2, 3, 5, 10, 12, 13, 17, 19, 21, 25, 26	4, 5, 9, 16, 22, 23, 26, 34	19, 21, 24, 31, 32, 35	4, 8, 19, 21, 23, 24, 26, 27, 31, 32, 34	2, 4, 8, 10, 16, 17, 20, 22, 23, 25, 26, 27, 32, 35
	R03	-	4, 23, 27	-	9, 16, 21, 24, 25, 31, 32, 34	21, 25, 26	4, 9, 16, 23, 26, 34	21, 24, 31, 32	4, 21, 23, 24, 26, 27, 31, 32, 34	4, 16, 23, 25, 26, 27, 32
	R04	-	17	29	5, 6, 17, 29, 34	5, 17	5, 34	-	34	17

		ID - Motivador								
		M01	M02	M03	M04	M05	M06	M07	M08	M09
	R05	19	1, 4, 13, 17, 19	29	1, 2, 6, 7, 10, 12, 13, 17, 18, 19, 21, 25, 29, 32	2, 10, 12, 13, 17, 19, 21, 25, 26	4, 26	19, 21, 32	1, 4, 19, 21, 26, 32	1, 2, 4, 10, 17, 25, 26, 32
	R06	22	22	22	5, 21, 24, 31, 34	5, 21	5, 22, 34	21, 24, 31	21, 24, 31, 34	22
	R07	19, 22	19, 22, 23	22	19, 24, 25, 32	19, 25	22, 23	19, 24, 32, 35	19, 23, 24, 32	22, 23, 25, 32, 35

Fonte: Elaborado pelos autores com base na literatura

A combinação dos dados apresentados no Quadro 3 permite estabelecer as relações de causa e efeito para tomada de decisão e estabelecimento das ações necessárias. Por exemplo, quando existe um grande volume de dados (M01) a ser analisado e o principal problema encontrado pelos gestores diz respeito a necessidade de melhorar ou ampliar o suporte para tomada de decisão (R02), a técnica de clusterização (T02), no contexto de *supply chain* (SC5) representa uma alternativa a qual pode ser considerada um ponto de partida para a solução do problema em foco. Quando a necessidade do negócio é melhorar a previsibilidade de indicadores de desempenho (M04) e melhorar acuracidade (R05), o uso de Regressão (T02) e Séries Temporais (T10), são indicadas nos contextos de S&OP (SC3 e SC4), Financeiro (SC2) e Custos (SC1).

O uso combinado dos resultados mapeados, demonstrou ganhos específicos para os negócios. Estes ganhos estão associados a previsibilidade de modelagem do fluxo de caixa, identificação dos *drivers* (impulsionadores) do negócio, identificação das áreas do orçamento que precisam de atenção. Deste modo, com a utilização de DS, as limitações dos softwares de planilhas eletrônicas são significativamente reduzidas, promovendo melhora da visibilidade, previsibilidade, confiabilidade e agilidade do negócio. Além disso, a DS disponibiliza informações atualizadas e acuradas para os analistas e *stakeholders*, diminuindo o tempo gasto em previsões e na estruturação dos seus processos. Embora não seja o foco deste estudo, fatores críticos de sucesso, associados ao processo de implementação das tarefas de DS, puderam ser identificados. Entre eles, a colaboração entre gestores e área de TI (tecnologia da informação) é ainda mais importante quando há demanda por análise de dados complexos, em grande escala, que demandam alto poder computacional, bem como o modo como os dados são combinados pode gerar diversos cenários possíveis e influenciar diferentes decisões a partir de um mesmo conjunto de dados.

5. Considerações finais

Esta pesquisa demonstrou como as aplicações de *Data Science & Analytics* (DS) podem contribuir para a gestão empresarial. As principais conclusões desta pesquisa estão associadas a seus resultados. De modo geral, a revisão sistemática da literatura possibilitou a sistematização das pesquisas que relacionam as aplicações e contribuições de *Data Science & Analytics* (DS) na gestão empresarial, o que contribui para o campo de pesquisa. A combinação de contexto, tarefas, desafios (motivadores) e resultados, trata-se de uma proposição única na literatura, o constitui-se a principal contribuição deste estudo. Por meio do *framework* proposto, os gestores de negócios podem identificar as principais técnicas de DS recomendadas para cada tipo de problema associado ao contexto dos negócios, em especial, na previsão e modelagem de variáveis que influenciam a gestão empresarial, comparando com a realidade da empresa. Este diagnóstico inicial permite a identificação dos problemas, que podem ser resolvidos por meio do uso da DS. Além disso, o *framework* proposto auxilia na identificação dos principais resultados que podem ser esperados a partir do encaminhamento das ações propostas. Compreender a inserção destas combinações, no contexto empresarial, pode ser relevante para o sucesso do negócio, uma vez que tendem a melhorar a acuracidade dos dados para tomada de decisão.

Este estudo foi limitado aos artigos das bases SCOPUS, CAPES e WoS. Entretanto, observou-se a escassez de artigos com detalhamento do contexto de negócio nos estudos analisados, o que reduziu o *corpus* de análise. Assim, a principal limitação da pesquisa está relacionada aos estudos que não apresentam resultados práticos ou apresentam resultados associados a aplicação das tarefas sem detalhamento do contexto. Deste modo, uma oportunidade de pesquisa futura trata-se da ampliação do *corpus* de análise por meio da consulta a outras bases de dados ou ao uso de técnicas como a bola de neve. Outra oportunidade de pesquisa futura é a adição de outros compomentes empresariais, tais como, processos específicos executados pelas áreas e funções da estrutura organizacional, ou ainda aos fatores criticos de sucesso para o uso de DS no contexto dos negócios, o que não foi abordado por esta pesquisa.

REFERÊNCIAS

BARDIN, Laurence. Análise de conteúdo. 1. ed. São Paulo: Edições 70, 2011. E-book.

BAZARAA, SHERALI; SHETTY. **Nonlinear Programming: Theory and Algorithms**, 2013.

BECKER, S. D.; MAHLENDORF, M. D.; SCHÄFER, U.; THATEN, M. **Budgeting in times of economic crisis**. Contemporary Accounting Research, 2016.

BRIGHAM, E. F.; EHRHARDT, M. C. **Financial Management: Theory and Practice**, 2016.

CAFFO, Brian; PENG, Roger D.; LEEK, Jeffrey. **Executive Data Science: A Guide to Training and Managing the Best Data Scientists**. 2018.

DAVENPORT, Thomas; HARRIS, Jeanne. **Competing on Analytics: The New Science of Winning**, 2007.

DRESCH, A.; LACERDA, D. P.; ANTUNES JÚNIOR, José Antônio Valle. **Design science research: a method for science and technology advancement**. New York: Springer, 2015. *E-book*. Disponível em: https://doi.org/10.1007/978-3-319-07374-3

DOMINGOS, Pedro. **O Algoritmo Mestre Como a busca pelo algoritmo de machine learning**. São Paulo: Editora Novatec, 2015.

ERMEL, Ana Paula, *et al*. Literature Reviews: Modern Methods for Investigating Scientific and Technological Knowledge. Springer, 2022.

GIUDICI, P. **Financial data science. Statistics & Probability Letters**. 2018

HEY, T.; TANSLEY, S.; TOLLE, K. **The Fourth Paradigm: Data-Intensive Scientific Discovery**. Washington, 2009.

HILTON, R. W.; PLATT, D. E. **Managerial accounting: creating value in a dynamic business environment**. McGraw-Hill Education, 2013.

LAPCHAK, PAUL & ZHANG, JOHN. **Data Standardization and Quality Management. Translational Stroke Research**. 9. 10.1007/s12975-017-0531-9, 2018.

LI, S., PENG, G. C., & XING, F. **Barriers of embedding big data solutions in smart factories: insights from SAP consultants. Industrial Management & Data Systems**, 2019.

LUNKES, Rogério João. **Manual de orçamento. 2 ed**.. São Paulo: Atlas, 2007.

OHLSON, Nils-Erik *et all*. **Identification of Tasks to Be Supported by Machine Learning to Reduce Sales & Operations Planning Challenges in an Engineer-to-Order Context.** IOS Press BV**,** 2022.

PROVOST, F., FAWCETT, T. **Data Science for Business**. Califórnia, EUA: O'Reilly Media. 2013

SILVA, Geraldo Luiz F. da. **Sistemas de informação: Teoria e exercícios.** Cacoal-RO: Priint Impressões Intelligentes, 2024.

VAN DER AALST, W. **Process Mining**: **Data Science in Action** (pp. 3-23). Berlin, Heidelberg: Springer, 2016.

VERMEULEN, Andreas François. **Practical Data Science: A Guide to Building the Technology Stack for Turning Data Lakes into Business Asset.** Reino Unido, Apress, 2018.

VICARIO & COLEMAN. **A Review of Data Science in Business and Industryand a Future View**. 2019

WASSERBACHER, Helmut & SPINDLER, Martin. **Machine learning for financial forecasting, planning and analysis: recent developments and pitfalls**. Springer International Publishing, 2022.

APÊNDICE A - Estudos que compõem o *corpus* de análise

ID	Título	Autor	Ano
1	Persistência Na Variância E Quebras Estruturais Nas Séries de Preços das Frutas no Mercado Produtor de Juazeiro (Ba).	DE OLIVEIRA, A.M.B.; EMÍDIO, T.F.D.	2017
2	Forecasting Time Series Using Neural Networks on The Example of Primary Sales of a Pharmaceutical Company.	GALKIN, D.; DUDKINA, T.; MAMEDOVA, N.	2022
3	Machine Learning for Financial Forecasting, Planning And Analysis: Recent Developments and Pitfalls	WASSERBACHER, H.; SPINDLER, M..	2022
4	Gerando Planos De Produção Através de um Problema Linear Quadrático Gaussiano com Restrições nas Variáveis de Decisão	SILVA FILHO, O.S.	2010
5	Expressway Project Cost Estimation with a Convolutional Neural Network Model	XUE, X.; JIA, Y.; TANG, Y.	2020
6	Throughput Forecasting of Different Types of Cargo in The Adriatic Seaport Koper	DRAGAN, D.; KESHAVARZSALEH, A.; INTIHAR, M.; POPOVIĆ, V.; KRAMBERGER, T.	2021
7	Passenger Demand Forecasting in Scheduled Transportation	BANERJEE, N.; MORTON, A.; AKARTUNALI, K.	2020
8	On The Application of Optimal Control Theory to Financial Planning and Forecasting	VASCONCELLOS, G. M.	1988
9	Variáveis Dos Custos De Produção Versus Preço De Venda da Cultura ao Café no Segundo Ano da Lavoura	DUARTE, S.L.; PEREIRA, C.A.; TAVARES, M.; DOS REIS, E.A.	2011
10	An Efficient and Simplified Model for Forecasting Using Srm	HAFIZ M. S.A.; MUHAMMAD. F.H.; TAUQIR, A.	2014
11	Strategies In Small and Medium-Pems: A Simulation Model to Forecast the Need for Working Capital in a Sme of the Furniture sector	BONACIM, C.A.G.; AMBROZINI, M.A.; PACAGNELLA JÚNIOR, A.C.; BONIZIO, R.C.	2008
12	Critical Success Factors of Integrated System of Production, Sales and Distribution	TAKEYASU, K.	2005
13	Realization of the Complex Forecast of an Enterprise's Cash Flows	IANKOVYI, O.; KOSHELEK, H.; IANKOVYI, V.	2017
14	Cost Prediction Model Based on System Dynamics in Water Resource Project	HIRIJANTO, M.I.W.; UTOMO, A.	2019
15	Fatores Determinantes Para o Risco de Liquidez em Micro e Pequenas Empresas da Cidade de Viçosa-Mg	PEREIRA, J.; DE ARAÚJO, J.M.; DE FARIA. R.E.; DOS SANTOS, L.M.	2020
16	Application of Fuzzy Mathematics to Determination of Budget Tourist Facilities	BETANCOURT, R. R.; MÁRTIR, M. E.	2016
17	Innovating Knowledge and Information for a Firm-Level Automobile Demand Forecast System: a Machine Learning Perspective	KIM S.	2023
18	Procurement Forecasting in Enterprise Resource and Planning (ERP) System Using Hybrid Time Series Model	EL MADANY H.; ALFONSE M.; AREF M.	2022
19	Identification of Tasks to Be Supported by Machine Learning to Reduce Sales & Operations Planning Challenges in an Engineer-To-Order Context	OHLSON, N.E.; RIVEIRO M.; BÄCKSTRAND, J.	2022
20	Early Stage Construction Cost Prediction in Function of Project Sustainability	CAR-PUŠI, D.; MLADEN M.	2020
21	Using Artificial Intelligence Technologies to Predict Cash Flow	DADTEEV, K.; SHCHUKIN, B.; NEMESHAEV, S.	2020
22	Difference in Differences in Marketing Performance Measurement	DENG W.; XU N.; LI H.; LIU F.; SHI Y.	2019
23	A Flow-To-Equity Approach to Coordinate Supply Chain Network Planning and Financial Planning With	STEINRÜCKE, M.; ALBRECHT, W.	2016

	Annual Cash Outflows to an Institutional Investor		
24	Short Interval Control for the Cost Estimate Baseline Of Novel High Value Manufacturing Products-a Complexity Based Approach	SCHWABE, O.; SHEHAB, E.; ERKOYUNCU, J.	2016
25	On The Robustness of Arima-Based Benchmarks for Corporate Financial Planning Quality	MARTIN, J.; SETZER, T.	2014
26	A Drug Cost Model for Injuries Due To Road Traffic Accidents	RIEWPAIBOON, A.; PIYAUTHAKIT, P.; SRIJARIYA, W.; CHAIKLEDKAEW, U.	2008
27	Financial Planning With Fractional Goals	GOEDHART, M.H.; SPRONK, J.	1995
28	Predicting Salability of Timber Sale Offerings In The Forest Service Northern Region	NICCOLUCCI, M.J.	1989
29	Why Are the Sales Forecasts So Low? Socio-Technical Challenges of Using Machine Learning for Forecasting Sales in a Bakery	FRIES, M; LUDWIG, T.	2022
30	Optimizing Data-Driven Network Under Limited Resource: A Partial Diversification Approach	WU, D.X; WU, D.D; KWON, R.H.	2019
31	Scheduling Optimization and Risk Analysis for Energy-Intensive Industries Under Uncertain Electricity Market to Facilitate Financial Planning	GANGWAR, S.; FERNANDEZ, D.; POZO, C.; FOLGADO, R; JIMENEZ, L.; BOER, D.	2023
32	Discovery and Prediction of Stock Index Pattern Via Three-Stage Architecture of Ticc, Tpa-Lstm and Multivariate Lstm-Fcns	OUYANG, HB; WEI, XL; WU, QF	2020
33	Use and Misuse Of Information in Supply Chain Forecasting of Promotion Effects	FILDES, R.; GOODWIN, P.; ONKAL, D.	2019
34	Financial Modeling Applied In Companies in The Manufacturing Sector in The City Of Santo Domingo De Los Tsachilas, Ecuador	PENATE, M.U.; *et.al.*	2021
35	The Impact of Financial Fragility on Firm Performance: An Analysis of Bist Companies	TUZCUOGLU, T.	2020